



PRUEBA ANALÍTICA · MLOPS + LLMOPS

Modelo de Opciones de Pago para Cobranza

De predecir la aceptación de pago al agente de IA que negocia alternativas



Jorge Sebastián Mora Lara



Agenda de la sesión

01

Contexto y objetivo

02

MLOPS · Análisis de datos, Construcción dataset de entrenamiento

03

MLOPS · Modelos y resultados

04

LLMOPS · Flujo agéntico

05

Pruebas del agente

06

Próximos pasos



Objetivo

Generar una estrategia MLOps y LLMOps para solucionar un el ofrecimeinto de opciones de pago



MLOps

Construir un Pipeline de modelamento que permita obtener un modelo que identifique que clientes aceptaran una opción de pagos.



LLMOps

Construir un flujo agéntico que permita la ineracción con clientes para la negociación de opciones de pago.



Exploración estadística y partición temporal

Objetivo

Predecir con un **modelo de clasificación** si un cliente en mora aceptará una opción de pago, y negociar las alternativas con un **agente de IA (LLM)**.


Variable objetivo: var_rpta_alt




48%

aceptó opción de pago


Clases balanceadas (~48% / 52%)



Registros por fecha —maestra_cuota




Registros por fecha — master_customer_data



Registros por fechas — probabilidad modelos

Construcción dataset de entrenamiento



Diagramas de caja — probabilidades modelos

Partición cronológica (OOT)

Meses train: [(2023, 7), (2023, 8), (2023, 9), (2023, 10)]

Meses test: [(2023, 11)]

train: (467785, 394), test: (100466, 394)

Dataset final


389

variables construidas

Ingeniería de variables

- Autorregresivas (1 y 2 meses)
- Promedios de probabilidades de cobranza
- Recurrencia y nº de obligaciones
- Ratios financieros + log de asimétricas.
- Usar la variable de objective de meses anteriores como información adicional
- Codificar variables categoricas.
- Imputación de nulos

Selección de variables por importancia



Top 20 variables más importantes — Random Forest (umbral de importancia > 0.001)

```
if MODELO == "random_forest":
    params = {
        "n_estimators": trial.suggest_int("n_estimators", 100, 300, step=50),
        "max_depth": trial.suggest_int("max_depth", 3, 20),
        "min_samples_split": trial.suggest_int("min_samples_split", 2, 20),
        "min_samples_leaf": trial.suggest_int("min_samples_leaf", 1, 20),
        "max_features": trial.suggest_categorical("max_features", ["sqrt", "log2", None]),
        "random_state": 42,
        "n_jobs": -1,
    }
    return RandomForestClassifier(**params)
else:
    params = {
        "max_depth": trial.suggest_int("max_depth", 2, 20),
        "min_samples_split": trial.suggest_int("min_samples_split", 2, 20),
        "min_samples_leaf": trial.suggest_int("min_samples_leaf", 1, 20),
        "criterion": trial.suggest_categorical("criterion", ["gini", "entropy"]),
        "random_state": 42,
    }
    return DecisionTreeClassifier(**params)
```

Definición de modelos con optimización de hiperparámetros (Optuna)

Reducción de dimensionalidad

389 → 140

–64% de variables → modelo más mantenible, rápido de entrenar y menos propenso a sobreajuste.

Búsqueda de grilla y desempeño del modelo

~80

modelos entrenados

0.71

AUC del mejor modelo

```
{'tipo_modelo': 'gradient_boosting',  
'n_estimators_gb': 250,  
'max_depth_gb': 8,  
'learning_rate_gb': 0.028661738782261057,  
'subsample_gb': 0.8831905581567937,  
'min_samples_split_gb': 11,  
'min_samples_leaf_gb': 10}
```


Mejores hiperparámetros — Gradient Boosting

```
{'tipo_modelo': 'extra_trees',  
'n_estimators': 350,  
'max_depth': 30,  
'min_samples_split': 5,  
'min_samples_leaf': 2,  
'max_features': None,  
'criterion_bosque': 'entropy'}
```

Mejores hiperparámetros — Extra Trees

Conclusiones clave


- Las variables calculadas fueron las de mayor impacto y las que elevaron la métrica.
- Las probabilidades de cobranza (auto-cura, propensión, alerta temprana) son las más predictivas.
- La info demográfica aporta poco → candidata a retirar o reemplazar.



AUC — modelo sin normalizar (búsqueda de umbral)

Agente negociador construido en n8n

Flujo escalable y personalizable, alineado a los lineamientos de construcción de agentes de Bancolombia.



1

Identificación

2

Memoria caché

3

Camino campaña

4

Camino reactivo

5


Guardado caché

6

Negociador


Los 6 módulos del flujo, en detalle

Identificación origen de la comunicación




1 · Identificación del origen de la comunicación

Validación de identidad del cliente




2 · Validación de identidad del cliente

Consulta de información de las alternativas del cliente




3 · Consulta de alternativas (campana)

Identificación de identidad del cliente y consulta de información de alternativas




4 · Identificación y consulta (reactivo)



5 · Guardado en caché (una sola vez)

Negociador de alternativas



6 · Negociador de alternativas (LLM)

El corazón del agente: negociación opciones de pago

Agente LLM


GPT-5 mini

Suficientemente potente para la negociación en pruebas iniciales.

Herramienta MCP

Catálogo de alternativas consultado por identificador → menos tokens y más mantenible.

Prompt con reglas de tono, marca, cumplimiento y anti prompt-injection.



Módulo negociador de alternativas en n8n (agente LLM + herramientas)

Por qué este diseño

- Se adapta las interacciones por campaña y reactivas con un mismo flujo.
- Optimiza y limita las llamadas a APIs y MCPs a puntos específicos.
- Mayor robustez frente a prompt-injection: no siempre puede consultar datos sensibles.

El agente en acción: conversaciones de prueba

hola

Hola, soy un agente de inteligencia artificial de Bancolombia. Para identificarte y revisar si tienes alguna alternativa preaprobada, por favor confirmamos tu cédula o NIT.

Interacción entrante: identificación del cliente

Hola, mi nit es 24588

Perfecto, gracias por la información. Confirmamos tu NIT 24588.

Resumen rápido: tienes un crédito rotativo en mora 32 días, con saldo vencido de \$43.471. Tenemos 3 alternativas preaprobadas para ponerte al día:

- CON24 — Combo reestructuración.
- CON26 — Prórroga reestructuración.
- CON22 — Reestructuración novación.

La cuota estimada para poner la obligación al día sería aproximadamente \$43.492 mensuales. Si eliges cualquiera de estas opciones procedemos a aplicarla y te dejamos en reestructuración para normalizar la cuenta.

Negociación: resumen de deuda y alternativas preaprobadas

no me interesa la reestructuración, que otras alternativas hay?

Lo entiendo. Lo lamento no hay otras alternativas disponibles.

La única opción preaprobada para tu obligación es la reestructuración (novación/consolidación). Si quieres, te explico cómo funciona y qué implicaría en montos y plazo, o la activamos ahora para ponerte al día.

Manejo de objeciones y alternativas al cliente

50 escenarios de prueba del agente

50

escenarios propuestos

Métricas

- Seguimiento de puntos claves en la conversación.
- Consistencia de la conversación.
- Manejo de intent de prompt injections.
- Uso correcto de herramientas.

Cubren desde clientes que aceptan fácilmente hasta casos difíciles, fallas operativas y ataques de seguridad:

1

Campaña saliente

Mora temprana, alternativas múltiples, rechazo

2

Interacción entrante

Acuerdos, consulta de deuda, autenticación

3

Identidad

Documento válido/erróneo, suplantación

4

Alternativas

Única, múltiples, vencidas, inconsistencias

5

Seguridad

Prompt injection, extracción de reglas

6

Operación y cumplimiento

Servicios caídos, timeouts, menores de edad

Del piloto a la producción

Modelo (MLOPS)

- 1 Calendarizar las ETLs de la información insumo.
- 2 Poner el modelo en producción vía Orquestador 2.
- 3 Monitoreo de métricas de desempeño.
- 4 Reentrenamiento automático por umbral.
- 5 Búsqueda de grilla si el reentrenamiento no basta.
- 6 Tablero Power BI de desempeño.

Agente (LLMOPS)

- 1 Probar todos los casos con métricas de efectividad.
- 2 Productizar y crear MCP del catálogo de alternativas.
- 3 Productizar MCP de preaprobadas por cliente.
- 4 Migrar a QA con conexiones MCP reales.
- 5 Piloto con usuarios dummy y ajustes.
- 6 Producción por subconjunto → masificación.



EN RESUMEN

Un pipeline de punta a punta: de predecir la aceptación a negociarla



Modelo predictivo

AUC 0.71 con ~80 modelos iterados y variables calculadas de alto impacto.



Agente negociador

Flujo n8n seguro y escalable con GPT-5 mini y guardrails.



Listo para escalar

Roadmap claro de MLOPS y LLMOps hacia producción monitoreada.

¿Preguntas? · Jorge Sebastián Mora Lara · jormora@bancolombia.com.co

